$ Aide-mémoire Kubernetes

Les commandes et notions essentielles de Kubernetes, groupées par usage.
Chaque partie d'une commande garde toujours la même couleur pour qu'on la repère d'un coup d'œil.

```
commande racine sous-commande option / flag valeur à remplacer
```

Qu'est-ce que Kubernetes (K8s) ?

Kubernetes est un système open source qui **automatise le déploiement, la mise à l'échelle et la gestion des applications conteneurisées**. Là où Docker lance des conteneurs sur une machine, Kubernetes les orchestre sur un ensemble de machines (un *cluster*) : il décide où les placer, en relance automatiquement en cas de panne et en ajoute ou en retire selon la charge.

L'abréviation **K8s** vient du nombre de lettres entre le « K » et le « s » de Kubernetes (8). On pilote un cluster avec l'outil en ligne de commande `kubectl`.

En pratique, Kubernetes aide à **lancer et gérer automatiquement de nombreux conteneurs**. Exemple : une application découpée en microservices (`users`, `products`, `orders`, `notifications`), chacun dans son conteneur Docker, à faire tourner sur plusieurs serveurs. Plutôt que de choisir à la main sur quel serveur lancer chaque conteneur, on décrit à Kubernetes ce qu'on veut obtenir, et il répartit lui-même les conteneurs sur les serveurs disponibles.

Ce que Kubernetes apporte

• **Déploiement automatique** (*Automatic Deployment*) : il simplifie le déploiement sur de nombreuses machines.
• **Disponibilité** (*Availability*) : il s'assure que les applications tournent toujours, même en cas de panne. Si un conteneur plante (ex. `users`), Kubernetes le détecte et en relance automatiquement un nouveau.
• **Mise à l'échelle** (*Scalability*) : il ajoute ou retire des instances d'un service selon le trafic. Si la charge augmente sur `products`, il lance des copies supplémentaires de ce conteneur, puis les retire quand la charge baisse.
• **Répartition de charge** (*Load balancing*) : il répartit le trafic entrant entre les différentes instances d'un même service, pour qu'aucune ne soit surchargée.

Un peu d'histoire

Kubernetes a été développé par **Google**, qui l'a rendu **open source en 2014**, puis confié à la **Cloud Native Computing Foundation (CNCF)**, qui assure aujourd'hui sa gouvernance.

Orchestration de conteneurs

L'**orchestration de conteneurs** est le processus qui consiste à **gérer automatiquement de nombreux conteneurs** : les **démarrer**, les **arrêter**, les **redémarrer** et les **mettre à l'échelle** (en ajouter ou en retirer). Kubernetes est l'outil d'orchestration le plus répandu.

Les fonctionnalités d'orchestration de Kubernetes

• **Déploiement automatisé** (*Automated deployment*) : on décrit l'état voulu (quelle image, combien d'instances), Kubernetes s'occupe de le mettre en place.
• **Mise à l'échelle** (*Scaling*) : augmenter ou réduire le nombre d'instances d'un service, manuellement ou selon la charge.
• **Planification** (*Scheduling*) : choisir sur quel serveur placer chaque conteneur, selon les ressources disponibles. Exemple : plusieurs instances de `users` réparties sur différents serveurs, `products` regroupé sur un autre.
• **Auto-réparation** (*Self-healing*) : relancer automatiquement un conteneur qui plante, ou le déplacer si un

serveur tombe en panne.
• **Répartition de charge** (*Load balancing*) : répartir le trafic entre les instances d'un même service.
• **Mises à jour progressives** (*Rolling updates*) : passer à une nouvelle version de l'application en remplaçant les instances une par une, sans interruption de service.
• **Retours arrière** (*Rollbacks*) : revenir rapidement à la version précédente si la nouvelle pose problème.
• **Découverte de services** (*Service Discovery*) : permettre aux services de se trouver par leur nom, sans connaître les adresses IP des conteneurs, qui changent à chaque redémarrage. C'est essentiel dans une **architecture microservices**, où les services s'appellent en permanence : `orders` appelle simplement `http://users/…`, et Kubernetes l'oriente vers une instance disponible de `users`, quel que soit le serveur où elle tourne. Kubernetes intègre ce mécanisme nativement (via ses *Services* et son DNS interne), là où une application Spring Cloud classique utilise un annuaire dédié comme Eureka.

Architecture d'un cluster

Pod

Le **Pod** est la **plus petite unité** que Kubernetes déploie et gère. Il enveloppe un conteneur (parfois plusieurs, très liés), par exemple celui d'une application Spring Boot, et lui fournit :
• un **stockage partagé** (volumes accessibles à tous les conteneurs du Pod) ;
• un **réseau partagé** : une adresse IP propre au Pod, ses conteneurs communiquent entre eux via `localhost` ;
• des **métadonnées** sur l'environnement dans lequel il tourne (nom, labels, namespace…).
On ne lance donc pas directement des conteneurs dans Kubernetes, mais des Pods.
En pratique, un Pod contient **le plus souvent un seul conteneur** ; plusieurs conteneurs ne se regroupent dans un même Pod que s'ils doivent vraiment fonctionner ensemble (ex. une application et un conteneur annexe qui collecte ses logs). **Chaque Pod reçoit sa propre adresse IP** dans le cluster (ex. `10.1.0.160`), ce qui permet aux Pods de communiquer directement entre eux, même sur un même Node.
Les conteneurs d'un même Pod peuvent **partager des volumes de stockage** : un volume monté dans le Pod est accessible par chacun de ses conteneurs, et peut s'appuyer sur un stockage externe (ex. stockage cloud) pour que les données survivent au Pod.
Enfin, les Pods sont **éphémères** : ils peuvent être supprimés et recréés à tout moment (panne, mise à jour, mise à l'échelle), et un Pod recréé reçoit une **nouvelle adresse IP**. On ne s'appuie donc jamais sur l'IP d'un Pod ni sur les données écrites dans son conteneur : on passe par un nom de service stable, et par des volumes pour les données à conserver.

Node (nœud de travail)

Un **Node** est une machine (physique ou virtuelle) du cluster qui **exécute les Pods**. Un cluster en compte généralement plusieurs : si un Node tombe en panne, Kubernetes recrée ses Pods sur un autre Node encore disponible (auto-réparation). Chaque Node fait tourner trois composants :
• **`kubelet`** : l'agent du Node. Il démarre et arrête les conteneurs, vérifie qu'ils restent en bonne santé, leur attache le stockage dont ils ont besoin, et rend compte de ce qui tourne au Control Plane ;
• **`kube-proxy`** : gère les règles réseau du Node pour que le trafic destiné à un service atteigne le bon Pod (base de la découverte de services et de la répartition de charge) ;
• le **runtime** de conteneurs (ex. `containerd`) : le logiciel qui exécute réellement les conteneurs à partir des images.

Control Plane (plan de contrôle)

Le **Control Plane** est un ensemble de **composants de gestion** qui tournent sur une ou plusieurs machines dédiées (souvent trois, pour qu'il reste disponible si l'une tombe). C'est le « cerveau » du cluster : il reçoit les demandes (par exemple via `kubectl`), décide sur quel Node placer chaque Pod, et surveille en permanence que l'état réel correspond à l'état voulu. Il communique en continu avec le `kubelet` de chaque Node.

Ses composants :
• **`kube-api-server`** : expose l'**API Kubernetes**. C'est le point d'entrée unique du cluster : `kubectl`, les autres composants du Control Plane et le `kubelet` de chaque Node passent tous par lui ;
• **`etcd`** : base de données **clé-valeur hautement disponible** qui stocke toutes les données du cluster (état voulu, état réel, configuration). Seul le `kube-api-server` y lit et y écrit ;
• **`kube-scheduler`** : surveille les **Pods nouvellement créés** qui n'ont pas encore de Node, et choisit le Node où les placer. Il tient compte des besoins en ressources (CPU, mémoire), des règles d'affinité et d'anti-affinité (placer des Pods ensemble ou au contraire les séparer), de la localité des données, des interférences entre charges de

travail et des délais ;
• `kube-controller-manager` : exécute les **contrôleurs**, des boucles qui comparent en permanence l'état réel à l'état voulu et corrigent les écarts (ex. recréer un Pod disparu pour garder le bon nombre d'instances) ;
• `cloud-controller-manager` : fait le lien avec l'**API du fournisseur cloud** (AWS, Azure, GCP…), par exemple pour créer un load balancer ou gérer les machines. Absent sur un cluster local.

Du déploiement au Pod : le parcours d'une demande

1. Le développeur construit l'image de son application et écrit une **spécification de déploiement** (fichier YAML décrivant l'état voulu).
2. Il l'envoie au cluster (avec `kubectl`) : le `kube-api-server` la reçoit et l'enregistre dans `etcd`.
3. Le `kube-scheduler` repère le nouveau Pod sans Node et choisit le Node le plus adapté.
4. Le `kubelet` de ce Node, informé via le `kube-api-server`, demande au **runtime** de lancer le conteneur : le Pod démarre.
5. `kube-proxy` met en place les règles réseau pour que le Pod soit joignable, et le `kube-controller-manager` veille ensuite à ce que l'état voulu reste respecté.

Cluster

Le **cluster** est l'ensemble formé par le **Control Plane** et les **Nodes de travail** qui exécutent les Pods. C'est à ce cluster que l'on s'adresse avec `kubectl`.

Deployment

Un **Deployment** décrit l'**état voulu** d'une application : quelle image lancer et combien de Pods identiques (*réplicas*) doivent tourner. Kubernetes crée ces Pods, les répartit sur les Nodes, et veille en permanence à ce que leur nombre reste celui demandé. Il couvre tout le cycle de vie de l'application :
• **Déployer** (*Deploy*) : créer les Pods à partir de l'image indiquée ;
• **Mettre à l'échelle** (*Scale*) : augmenter ou réduire le nombre de réplicas ;
• **Mettre à jour** (*Update*) : passer à une nouvelle version de l'image en remplaçant les Pods **progressivement**, quelques-uns à la fois, pour que l'application reste disponible pendant toute la mise à jour (*rolling update*) ;
• **Revenir en arrière** (*Rollback*) : si la nouvelle version pose problème, revenir à la version précédente, elle aussi de façon progressive ;
• **Auto-réparation** (*Self-healing*) : si un Pod plante ou disparaît (ex. son Node tombe en panne), le Deployment le **remplace automatiquement** par un nouveau Pod, pour toujours garder le nombre de réplicas demandé ;
• **Suivi de l'état** (*Status check*) : le Deployment indique en permanence où en est l'application : combien de réplicas sont prêts et disponibles, et si une mise à jour est en cours, terminée ou bloquée.

```
kubectl create deployment <nom> \
  --image=<image> \
  --port=<port> \
  --replicas=<nombre>
```

Crée un Deployment : `--image` indique l'image de conteneur à lancer, `--port` le port sur lequel l'application écoute dans le conteneur, et `--replicas` le nombre de Pods identiques à faire tourner en permanence.

Conseil : sans `--replicas`, un seul Pod est créé. Le `\` en fin de ligne permet d'écrire la commande sur plusieurs lignes (Linux, macOS, Git Bash).

```
kubectl create deployment mon-service-deployment \
  --image=mon-compte/mon-service:2.0.1 \
  --port=8082 \
  --replicas=3
```

Exemple : déploie l'application à partir de son image publiée sur Docker Hub, qui écoute sur le port `8082`, en 3 exemplaires. Le `kube-scheduler` répartit les 3 Pods sur les Nodes disponibles, et Kubernetes en recrée automatiquement un si l'un d'eux disparaît.

```yaml
# mon-service-deployment.yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: mon-service-deployment
  labels:
    app: mon-service
    tier: backend
…
```

La même chose sous forme de fichier YAML (*manifeste*), la façon habituelle de décrire un Deployment : le fichier se versionne avec le code et se réapplique à l'identique. Le début de tout manifeste :
• `apiVersion` : la version de l'API Kubernetes qui définit ce type d'objet (`apps/v1` pour un Deployment) ;
• `kind` : le type d'objet décrit (`Deployment`) ;
• `metadata` : l'identité de l'objet, avec son `name` (unique) et ses `labels`, des paires clé-valeur libres (ex. `app: mon-service`, `tier: backend`) qui servent à classer et à sélectionner les objets.

Conseil : les labels ne sont pas décoratifs : c'est grâce à eux que Kubernetes relie un Deployment à ses Pods, ou un Service aux Pods vers lesquels envoyer le trafic. Choisis-les cohérents d'un fichier à l'autre.

Service

Le problème que résout un Service

Une application cliente située **hors du cluster** peut joindre un Node par son adresse (ex. `192.168.0.1`), mais **pas directement un Pod** par son IP (ex. `10.1.0.160`) : les IP des Pods appartiennent au réseau interne du cluster et ne sont pas accessibles de l'extérieur. Ce réseau des Pods s'étend sur **tous les Nodes** du cluster : un Pod du Node 1 (`10.1.0.160`) peut joindre directement un Pod du Node 2 (`10.1.0.162`), mais ce réseau reste fermé au monde extérieur.
Et même à l'intérieur du cluster, s'appuyer sur l'IP d'un Pod est fragile : les Pods sont éphémères, un Pod recréé change d'IP, et un Deployment en fait tourner plusieurs (`10.1.0.160`, `10.1.0.157`, `10.1.0.162`…) répartis sur différents Nodes. Il faut donc un **point d'accès stable** qui sache vers quels Pods envoyer le trafic : c'est le rôle du **Service**.

Répartition de charge

Le client n'appelle plus un Pod précis, mais le **Service**, qui a une adresse et un nom **stables**. Le Service connaît en permanence la liste des Pods qui correspondent à son application (retrouvés grâce à leurs *labels*) et **répartit les requêtes** entre eux (ex. tantôt vers `10.1.0.160`, tantôt vers `10.1.0.157`). Le Service joue ainsi le rôle de **répartiteur de charge** (*load balancer*), avec une répartition **aléatoire** par défaut : chaque nouvelle connexion part vers l'un des Pods disponibles, choisi au hasard, ce qui équilibre la charge en moyenne. Si un Pod disparaît ou si de nouveaux réplicas sont ajoutés, le Service met sa liste à jour automatiquement : le client, lui, ne change rien.

Comment un Service trouve ses Pods : les sélecteurs

Un Service ne connaît pas ses Pods par leur nom ni par leur IP : il les retrouve grâce à un **sélecteur** (*selector*), c'est-à-dire un ou plusieurs **labels** que les Pods doivent porter. Exemple : le Service *Frontend* a le sélecteur `tier: frontend` et envoie le trafic à tous les Pods étiquetés `tier: frontend` ; le Service *Backend*, avec `tier: backend`, ne vise que les Pods `tier: backend`. Tout Pod qui reçoit le bon label (par exemple un nouveau réplica) est automatiquement pris en compte par le Service.
Concrètement, le Service tient à jour une **liste d'endpoints** : les adresses IP des Pods qui correspondent à son sélecteur (ex. `10.1.0.161` et `10.1.0.162` pour le Service *Backend*). C'est vers ces adresses qu'il envoie le trafic. Quand un Pod est créé, supprimé ou recréé avec une nouvelle IP, la liste est mise à jour automatiquement.
Enfin, le Service n'envoie le trafic qu'aux **Pods en bonne santé**, prêts à répondre. C'est la **sonde de disponibilité** (*readiness probe*) qui le détermine : un test que Kubernetes exécute régulièrement sur chaque Pod (ex. un appel HTTP à une URL de santé de l'application). Tant que le test échoue, par exemple pendant le démarrage d'une application Spring Boot, le Pod est retiré de la liste d'endpoints et ne reçoit aucune requête ; il y est réintégré dès que le test réussit.

Communication interne et externe

Le Service est indispensable dans les deux sens :
• **Communication interne** : entre Pods du même cluster. Les Pods *frontend* n'appellent pas directement les IP des Pods *backend* (`10.1.0.161`, `10.1.0.162`), qui peuvent changer : ils appellent le **Service** du backend, qui transmet la requête à l'un des Pods backend disponibles.
• **Communication externe** : depuis l'extérieur du cluster. Une application cliente (navigateur, application mobile, autre système) ne peut pas joindre les IP des Pods : elle passe par un **Service** exposé à l'extérieur, qui reçoit la requête et la dirige vers les Pods concernés (frontend ou backend).
Dans les deux cas, le Service offre le même avantage : un point d'accès stable et une répartition de charge, quels que soient le nombre de Pods et leurs adresses.

Les types de Services

• **`ClusterIP`** : accès **interne au cluster uniquement**. Le Service reçoit une IP virtuelle et un nom DNS joignables seulement depuis les Pods du cluster. C'est le type par défaut, utilisé pour la communication entre microservices (ex. frontend → backend).
• **`NodePort`** : accès **externe via un port des Nodes**. Kubernetes ouvre le même port (par défaut entre `30000` et `32767`) sur chaque Node du cluster ; une application cliente joint le Service à l'adresse `<IP d'un Node>:<NodePort>`, et la requête est transmise aux Pods. Le port est le même sur tous les Nodes (ex. `192.168.0.1:30080` et `192.168.0.2:30080`), et la requête peut atteindre un Pod situé sur **n'importe quel Node**, pas seulement celui qui l'a reçue.
• **`LoadBalancer`** : accès **externe via un répartiteur de charge du fournisseur cloud**. Sur un cluster cloud (AWS, Azure, GCP…), Kubernetes demande automatiquement au fournisseur, via le `cloud-controller-manager`, de créer un load balancer avec une **adresse IP publique** ; les clients utilisent cette adresse unique, et le load balancer répartit le trafic entre les Nodes du cluster. C'est le moyen le plus courant d'exposer une application en production.
• **`ExternalName`** : **alias DNS vers un service externe** au cluster. Le Service ne pointe vers aucun Pod : son nom renvoie simplement vers un nom de domaine extérieur (ex. une base de données hébergée dans le cloud, `db.exemple.com`). Les Pods appellent le nom du Service comme n'importe quel service interne ; si l'adresse externe change, seul le Service est à modifier, pas le code ni la configuration des applications.